



Neste documento encontra-se o relatório final que complementa algumas das ideias do projeto desenvolvido para a cadeira de ECAC. Trata-se de análises mais descritivas/profundas aos tópicos implementados, assim como comentários gerais acerca dos gráficos e resultados obtidos.

META 1

3.2. Analise e comente a densidade de *outliers* existentes no dataset transformado.

Atividade 1 (Stand): 11.23%

Atividade 2 (Sit): 12.28%

Atividade 3(Sit and talk): 13.05%

Atividade 4 (Walk): 6.30%

Atividade 5 (Walk and talk): 5.91%

Atividade 6 (Climb stairs): 6.87%

Atividade 7 (Climb stairs and talk): 6.55%

Atividade 8 (Stand -> sit): 21.62%

Atividade 9 (Sit -> Stand): 26.99%

Atividade 10 (Stand-> sit and talk): 20.66%

Atividade 11(Sit-> stand and talk): 26.86%

Atividade 12 (Stand -> walk): 13.31%

Atividade 13 (Walk -> stand): 10.31%

Atividade 14 (Stand->climb stairs, Stand->climb stairs and talk): 22.28%




Atividade 15 (Climb stairs and walk): 12.81%

Atividade 16 (Climb stairs and talk-> Walk and talk): 8.03%


Com base nos resultados obtidos podemos concluir que, após aplicação do método IQR, as atividades 8, 9, 10, 11 e 14 apresentam maior densidade de outliers. De maneira geral, quase todas as atividades que apresentam transições muito “brutas” (ou seja, por exemplo, que apresentem diferenças entre o acelerómetro drásticas) contém um maior número de outliers comparativamente às outras. Porém, também é de notar que há certas atividades de transição que apresentam resultados diferentes aos esperados, como é o caso das atividades 12 e 13, que deveriam mostrar resultados perto dos 20%.

3.5. Comparação entre a deteção de outliers utilizando dois métodos distintos.


Para começar, anexamos os gráficos que obtivemos por execução do código utilizando Z-Score (3.4), seguido de um boxplot de cada atividade utilizando o método IQR (3.1).




Deteção de Outliers com Z-Score (k=3) - Módulo do Magnetômetro




Deteção de Outliers com Z-Score (k=3.5) - Módulo do Magnetômetro




Deteção de Outliers com Z-Score (k=4) - Módulo do Magnetômetro




Deteção de Outliers com Z-Score ($k=3$) - Módulo do Giroscópio




Deteção de Outliers com Z-Score ($k=3.5$) - Módulo do Giroscópio



Deteção de Outliers com Z-Score ($k=4$) - Módulo do Giroscópio



Boxplots para Todos os Dispositivos




Ao observarmos todos os gráficos mencionados, podemos concluir que há discordâncias bastantes evidentes. O método IQR é capaz de identificar um maior número de outliers do que o Z-score em algumas atividades, por exemplo na atividade 9, módulo de aceleração: no método IQR, obtemos um valor de $\pm 26\%$, enquanto no Z-score temos um valor mais próximo de 17% . Com o método IQR, dividimos os dados em quartis para medirmos a variabilidade dos mesmos, e com o Z-score assumimos uma distribuição normal e deduzimos os outliers graças a standard deviations.


Uma vez que estes dados não assumem este tipo de distribuição, a grande variação de valores altera o desvio padrão, tornando o método Z-Score bastante instável. Resumindo, quando os dados assumem uma distribuição mais simétrica, o Z-score deteta um maior número de outliers, e quando se observa uma distribuição mais assimétrica (como é o caso da atividade 9) é o método IQR que deteta mais.

3.7. Comparação dos resultados obtidos com os de 3.4.


Outliers k-Means para Disp 2, Ativ 4



Clusters k-Means (k=8) para Disp 2, Ativ 4



4.4. 1.PCA



Após a análise PCA deduzida, podemos concluir que, para explicar 75% do feature set, basta utilizarmos 22 dimensões.

Para podermos obter as features relativas a esta compressão, começamos por: normalizar o vetor das features com o Z-Score e projetar o vetor normalizado pelos 22 vetores com o objetivo de se obter um vetor que contenha features compressas. No código, foi escolhido o instante 0 para a exemplificação, sendo possível observar os seguintes resultados:

Features originais (segmento #0, 10 primeiras):

[-1.52298326
-1.2189
1.26823266
1.60841409
1.98189104
-0.00589506
-0.6755469
-0.73085059
1.8374
0.03921569]

Features PCA (reduzidas para 75% variação) para o exemplo 0:

[-5.08465391
-1.74245532
-3.50792645
0.02550576
0.88339312
-2.65871436
-3.47163771
1.48166745
-0.31895508
0.46017465]


4.4.2. Vantagens e limitações desta abordagem.

Após a implementação do PCA, podemos concluir algumas vantagens e limitações a este método, nomeadamente:

Vantagens: A redução significativa dos dados (mais especificamente, em 84.7%); a eliminação de dados descartáveis, ou de baixa significância;

Limitações: Os principais componentes (PC) não permitem diferenciabilidade física dos dados, uma vez que representam uma combinação linear de todas as features representadas; este método prioriza features com maior variância, não necessariamente as mais importantes.

4.6. Melhores features e comparação de resultados.



Por observação dos gráficos, podemos concluir que os dois testes mostram resultados completamente diferentes no que toca às melhores features. No caso do Fisher Score, as top3 features são F48, F46 e F52; enquanto com Relieff, os top3 são F105, F118 e F66. É de notar que, uma vez que os testes não partilham nenhuma feature na seleção, é crítica a escolha de um método para o desempenho final.

4.6.1. Obtenção de features relativas a uma seleção específica.

Para podermos obter as features relativas a esta seleção, começamos por determinar o ranking de importância de todas as features disponíveis; seguidamente, guardamos os índices originais das 10 melhores features e filtramos o vetor original para mantermos apenas estes índices. No código, foi escolhido o instante 0 para a exemplificação, sendo possível observar os seguintes resultados:

Features originais (segmento #0, 10 primeiras):

[-1.52298326
-1.2189
1.26823266
1.60841409
1.98189104
-0.00589506
-0.6755469
-0.73085059
1.8374
0.03921569]

Features seleccionadas pelo Fisher Score para o exemplo 0:

[48
46
52
47
104
35
37
90
96
91]

Features seleccionadas pelo Relieff para o exemplo 0:

[133
70
67
106
132
74
99
66
118
105]

4.6.2 Vantagens e Limitações desta abordagem.

Após a implementação destes dois algoritmos, podemos deduzir algumas vantagens e limitações que ambos apresentam, nomeadamente:

Vantagens para o Fisher Score: É excelente na diferenciação de features com uma diferença significativa na variância;

Limites para o Fisher Score: Não consegue lidar da melhor maneira com features redundantes nem com relações não-lineares entre as mesmas.

Vantagens para o Relieff: Ao contrário do Fisher Score, permite identificar features em problemas não-lineares através da análise de features vizinhas;

Limites para o Relieff: Como está sempre a analisar os vizinhos, é consideravelmente mais lento que o Fisher Score.

De maneira resumida, a seleção de features permite a estabilidade das features originais, garantindo a interpretabilidade física dos modelos, algo que não era garantido com o PCA.

META 2

3.3. Discuss the differences between the two strategies.

A estratégia Within-Subject compara os mesmos participantes sob diferentes condições, reduzindo a variabilidade; enquanto a estratégia Between-Subject compara grupos distintos de participantes, exigindo amostras maiores para compensar pela variabilidade individual. A estratégia Between-Subject oferece uma melhor estimativa na performance do modelo aplicada num novo participante, uma vez que se certifica de que o modelo não recolhe nenhum dado da pessoa durante o treino. Isto prova-se mais eficiente do que Within-Subjects, que reconhece o padrão dos participantes.

5.2. Report and analyse your results.

Após observação dos resultados, conclui-se que o DataSet_A, ou seja, as features, é significativamente melhor do que os embeddings (aproximadamente 21%).

No que toca à seleção de features, é possível verificar que melhoraram a performance deste dataset: o Relieff aprimorou a performance do Dataset_A, porém com a aplicação do PCA houve perda de informação crítica e, consequentemente, houve uma pior performance. Em relação ao Dataset_B, podemos concluir que, ao contrário das Features, os Embeddings são afetados negativamente com a seleção de features.

5.3. Perform Hypothesis Testing.

Analisando os dados, concluímos que obtivemos um $p\text{-value}=0$ ($p < 0.05$), o que nos leva a rejeitar a hipótese nula (H_0), confirmando que existem diferenças estatisticamente significativas entre os modelos (algo também garantido através da análise dos Rankings de Friedman, colocando a configuração Dataset_A_relief_Within-Subject em primeiro lugar absoluto). Assim, é possível validarmos que o método de seleção Relieff foi superior ao PCA, indicando que a projeção em PC resultou numa perda de variância discriminativa relevante para este problema.

7.1 Support Vector Machines (SVM) com Kernel RBF.

Após a observação dos dados, nota-se que o k-NN apresenta dificuldade em separar classes com sobreposição (ex: Walk vs Walk and Talk). O SVM com Kernel RBF ajuda a projetar os dados num espaço dimensional superior, que beneficia a separação de classes com sobreposição. Depois de uma observação dos dados notou-se que um C Elevado combinado com um Gamma moderado produz os melhores resultados, privilegiando o ajuste aos dados de treino sem comprometer a generalização.

7.2. Random Forest e Feature Importance.

O Random Forest permitiu uma análise à importância física de cada sensor. A análise do modelo revelou que as Features 8 e 14 foram as mais determinantes para a classificação, oferecendo uma explicação física para a distinção das atividades.

7.3. Leave-One-Subject-Out (LOSO).

Com o LOSO, o modelo é testado num participante completamente novo. Depois de se testar, analisam-se os resultados e verifica-se que o SVM com kernel RBF atinge uma accuracy média de 95,36% em LOSO, que comprova que o modelo tomou em consideração o padrão das atividades.

7.4. Calibração de Probabilidades.

Para garantir a segurança do sistema, aplicou-se o método de Platt Scaling, que permite transformar os scores do modelo em probabilidades reais. Observou-se uma descida da confiança média para valores mais conservadores, tornando o sistema mais fiável na tomada de decisão.